

Débitos Recurrentes

Prueba Técnica — Analítico III

Jhon Fredy Correa Gomez

Economista · Científico de Datos

Bancolombia · Gerencia de Inteligencia de Originación y Cobranza · 2026

Agenda

#	Tema	Tiempo
1	Contexto e impacto de negocio	2 min
2	Arquitectura y pipeline escalable	2 min
3	Hallazgos críticos del EDA	2 min
4	Feature engineering y selección	1 min
5	Modelos, resultados y diagnóstico AUC	3 min
6	Dashboard Metabase	2 min
7	Operacionalización con Airflow	1 min
8	Conclusiones, accionables y próximos pasos	2 min

Resumen ejecutivo — en 30 segundos

Métrica	Valor
AUC real del modelo (Gradient Boosting)	0.96 — Test; 0.96 — OOT
KS estadístico	0.73 — excelente separación de clases
Estabilidad	Train ≈ Test ≈ OOT — sin sobreajuste
Clase 1 (pagadores por débito)	78.8 % del universo (36,835 obligaciones)
Modelos desplegados	XGBoost · Gradient Boosting · Logistic Regression
Opción sin historial (B)	AUC 0.88 (solo gestiones + moras, 19 features)
Pipeline	CSV → PostgreSQL → Parquets → PKL → Metabase — 100 % automatizado
Diagnóstico AUC = 1.0	Identificado, explicado y resuelto — causa estructural del dataset

El modelo identifica con **AUC = 0.96** qué obligaciones en mora pagarán exclusivamente por débito recurrente, permitiendo **desactivar la gestión humana** en el 78 % de la cartera.

1. Contexto

Problema de negocio e impacto operativo

Problema de negocio

¿Qué se quiere resolver?

Identificar obligaciones en mora temprana (1–30 días) con **alta probabilidad de pagar exclusivamente por débito recurrente**, para reducir costos de cobranza y mejorar la eficiencia operativa.

Definición de la variable respuesta

Clase	Condición	Registros	%
<code>var_rta = 1</code>	Pagos únicamente por débito Y recurrencia ≥ 40 %	36,835	78.8 %
<code>var_rta = 0</code>	Sin patrón de pago registrado en el período	9,901	21.2 %

Condición doble simultánea: exclusividad de canal + frecuencia mínima ≥ 40 %.

Hallazgo crítico: clase 0 $\neq$ "pagó por otro canal" — significa **sin actividad de pago** en el período. Ver H1.

Desbalance **3.7:1** → estratificación + `class_weight` en todos los modelos.

Segmentación operativa de cobranza

Segmento	Criterio	Acción	Impacto
A — Automatizar	var_rta=1 y mora ≤ 10 días	Sin gestión humana	Ahorro máximo de costos
B — Monitorear	var_rta=1 y mora > 10 días	Seguimiento ligero	Reducción parcial de costos
C — Cobranza suave	var_rta=0 y mora ≤ 15 días	Contacto preventivo	Gestión focalizada
D — Cobranza intensiva	var_rta=0 y mora > 15 días	Gestión activa	Máximo esfuerzo

Palanca clave: el modelo predice `var_rta` con AUC = 0.96 → permite **concentrar el 100 % del esfuerzo humano en Segmentos C y D**, que representan el 21.2 % de la cartera.

Impacto directo en costos de cobranza

El modelo permite **priorizar** qué obligaciones NO necesitan gestión humana:

```
Universo en mora temprana: 45,731 obligaciones
├── Clase 1 predicha (AUC 0.96): ~36,000 obligaciones
│   ├── Segmento A (mora ≤ 10d): automatizar → sin costo de gestor
│   └── Segmento B (mora > 10d): monitoreo ligero
└── Clase 0 predicha: ~9,700 obligaciones → gestión focalizada C/D
```

Sin el modelo: gestión activa sobre las 45,731 obligaciones.

Con el modelo: gestión activa solo sobre ~9,700 (Segmentos C + D).

Reducción estimada de volumen de gestión: ~79 % — dependiente del umbral operativo elegido (actualmente KS-óptimo).

2. Arquitectura

Modelo de datos analítico y pipeline escalable

Fuentes de datos — 6 archivos CSV

Fuente	Filas	Cols	Contenido	Cobertura
clientes	46,736	4	Base maestra con var_rta	100 %
pagos (tanque)	47,194	67	Pagos por canal: débito, físico, virtual	100 %
gestiones	47,194	83	Gestiones de cobranza (acuerdos, RPC)	100 %
excedentes	47,194	35	Pagos sobre cuota y % de excedente	100 %
moras	47,194	12	Días de mora por ventana temporal	100 %
canales	10,801	4,258	Transacciones granulares por canal	20.7 %

Clave primaria compuesta: (num_doc, obl17, f_analisis)

Decisión: canales → LEFT JOIN + imputar 0 (S4); solo 3 cols de resumen para el modelo (S10)

Pipeline — flujo de datos end-to-end

```
CSV datalake/ (6 fuentes · 245K+ filas)
|
▼ T1: loader.py → PostgreSQL debitdb (6 tablas + dedup + S11)
|
▼ T2: data_preparation.py → analytical_model.parquet (JOIN 6 fuentes)
|
▼ T3: feature_engineering.py → train / test / oot .parquet (~240 features)
|
▼ T3.5: feature_selection.py → feature_cols.json
      (varianza → ANOVA → ElasticNet — fit solo en train)
|
▼ T4: train_debit_classifier.py → PKL + MLflow
      (XGBoost · GBM · LogReg · Optuna 5 trials · 12 figuras/run)
|
▼ T5: export_*_metrics.py → debit_model_metrics + debit_pipeline_metrics
|
▼ T6: metabase_provisioning.py → Dashboard id=4 (18 cards · idempotente)
```

Orquestado con Airflow DAG @monthly · cada tarea como DockerOperator sobre debit-network · gates
ShortCircuitOperator configurables

Infraestructura Docker — `debit_network`




Imagen	Base	Propósito
<code>debit-ml:latest</code>	Python 3.11 + UV	Pipeline ML, MLflow server, migraciones Alembic
<code>debit-airflow:latest</code>	<code>apache/airflow:2.8.1-python3.11</code>	Orquestación DAG + providers Docker/PostgreSQL

Particionamiento Train / Test / OOT

Partición	Rango temporal	Periodos	Filas
Train	2024-07 → 2025-02	8	22,293
Test	2025-03 → 2025-07	5	13,693
OOT	2025-08 → 2025-11	4	10,750

Justificación del esquema:

- Split temporal = validación rigurosa **fuera de muestra** en cohortes futuras
- OOT representa el comportamiento más reciente de la cartera
- Hallazgo H4: 97.9 % de obligaciones aparecen en un único `f_analisis` → dataset casi **transversal** → el split segmenta cohortes distintas (ver Sección 5)

Métricas de evaluación: AUC · KS · Precision / Recall / F1 · Brier Score · Log Loss · Calibración

3. EDA

Hallazgos críticos — lo que los datos revelan

Hallazgo H1 — El más importante del análisis

El 100 % de observaciones clase-0 tienen `total_pago = 0` en TODAS las ventanas y canales del tanque.

Variable (tanque)	Clase 0 (9,901 obs)	Clase 1 (36,835 obs)
<code>avg_pago_debito_3m</code>	0.00 — todas las obs	> 0 en pagadores
<code>avg_pago_fisico_3m</code>	0.00 — todas las obs	0 (exclusividad débito)
<code>avg_pago_virtual_3m</code>	0.00 — todas las obs	0 (exclusividad débito)
<code>avg_pago_otros_3m</code>	0.00 — todas las obs	0 (exclusividad débito)

Lo que esto cambia:

- `var_rta = 0` no significa "pagó por otro canal" → significa "sin actividad de pago"
- El objetivo real: **identificar quién va a pagar vs. quién no paga**
- Las features del tanque discriminan casi perfectamente → AUC = 0.96
- Explica el AUC = 1.0 con split temporal (ver Sección 5)

Hallazgos complementarios

ID	Hallazgo	Implicación
H2	14.9 % de clase-1 tiene pagos físico/virtual en ventana 3m	<code>var_rta</code> se calcula en <code>f_analisis</code> puntual; tanque promedia 3m previos → pequeña discrepancia esperada
H3	<code>rec_e_v</code> tiene solo 239 obs activas (< 0.1 %)	No usable como feature — el tanque es la fuente correcta de señal de débito
H4	97.9 % de obligaciones en un único <code>f_analisis</code>	Dataset casi transversal → split temporal segmenta cohortes distintas , no evolución de la misma obligación

Reconstrucción de `var_rta` desde el tanque

Estrategia	Concordancia	FP	FN
E1: avg_débito_3m > 0 + exclusividad	65.70 %	0	16,032
E2: prop_débito_3m ≥ 40 % + exclusividad	65.70 %	0	16,032
E3: avg_débito_12m > 0 + exclusividad	55.82 %	0	20,650
E4: min_débito_3m > 0 + exclusividad	65.38 %	0	16,181

Cero Falsos Positivos en todas las estrategias — el tanque 3m **nunca clasifica erróneamente un clase-0 como clase-1**.

La baja concordancia refleja que `var_rta` usa una ventana puntual distinta al promedio histórico del tanque.

Conclusión: la baja concordancia no es ruido — es una diferencia metodológica de ventanas temporales.

4. Features

Ingeniería y selección supervisada

Selección supervisada — 3 etapas, fit solo en train

```
~240 candidatas
|
▼ Varianza / Sparsity (umbral 0.01)
191 features (-49: canales granulares + zeros constantes)
|
▼ ANOVA F-test (percentil 80 – p-valor ajustado)
152 features (-39: pago_fisico y pago_otros ELIMINADOS → confirma H1)
|
▼ ElasticNet L1/L2 (l1_ratio=0.7, C=0.1)
60 features finales – Opción A (incluye débito)
19 features finales – Opción B (solo gestiones + moras)
```

Grupos finales (Opción A): gestiones=48 · pagos=24 · derivadas=21 · canales_resumen=4 · moras=9 · excedentes=9

Nota crítica: `pago_fisico` y `pago_otros` eliminados por ANOVA → **confirma empíricamente** que clase-0 = sin pago en ningún canal (H1). La selección supervisada encontró sola el hallazgo del EDA.

5. Modelos

Resultados, diagnóstico y decisión

Resultados — Opción A (60 features, incluye débito del tanque)

Modelo	Split	CV AUC	Test AUC	OOT AUC	KS Test
Gradient Boosting ★	Aleatorio	0.96	0.96	0.96	0.73
XGBoost	Aleatorio	0.96	0.96	0.96	0.73
Logistic Regression	Aleatorio	0.95	0.95	0.95	0.71
Gradient Boosting	Temporal	0.85	⚠ 1.00	⚠ 1.00	—
XGBoost	Temporal	0.84	⚠ 1.00	⚠ 1.00	—
Logistic Regression	Temporal	0.82	⚠ 1.00	⚠ 1.00	—

⚠ **AUC = 1.0 temporal** = artefacto estructural (H1 + H4) — ver diagnóstico.

Producción: split aleatorio · AUC real = **0.96** · Train $\approx$ Test $\approx$ OOT (sin sobreajuste).

Resultados — Opción B (19 features, sin historial de débito)

Modelo	Split	CV AUC	Test AUC	OOT AUC	Notas
Gradient Boosting ★	Aleatorio	0.89	0.89	0.88	Mejor opción B
XGBoost	Aleatorio	0.88	0.89	0.88	Estable
Logistic Regression	Aleatorio	0.87	0.88	0.87	Baseline robusto
Gradient Boosting	Temporal	0.75	0.92	0.90	Inflación parcial — moras tienen señal temporal
XGBoost	Temporal	0.75	0.93	0.91	KS test = 0.79
Logistic Regression	Temporal	0.74	0.93	0.93	KS test = 0.83

Features Opción B: solo **gestiones** (acuerdos, RPC, promesas, rank) + **moras** (avg/min/max/std × 3m/6m/9m)

Excluidas: 129 features de pagos · excedentes · canales · derivadas de débito

Nota sobre temporal B: sin features de pago el efecto H1 no aplica directamente, pero las features de moras también tienen señal temporal → test/OOT AUC (~0.92–0.93) supera el CV (~0.74–0.75). El split aleatorio (~0.88–0.89) es el referente de producción.

Valor de Opción B: AUC = 0.88 sin ningún dato de pago demuestra que el **comportamiento de cobranza per se** (gestiones, mora) tiene alto poder predictivo.

Diagnóstico — ¿Por qué AUC = 1.0 con split temporal?

Síntoma observado:

Split	CV Train	Test	OOT
Temporal (Opción A)	0.84	⚠ 1.00	⚠ 1.00
Aleatorio (Producción)	0.96	0.96	0.96

Causa: NO es leakage temporal clásico — las ventanas de features son previas a `f_analisis`.

Causa real — interacción de dos hechos estructurales:

Factor	Efecto
H1: Clase-0 tiene <code>total_pago = 0</code> en todo el tanque	Features de débito discriminan trivialmente a clase-0
H4: Dataset casi transversal (97.9 % en único período)	Split cronológico concentra clase-0 en cohortes de Test/OOT

→ En Test/OOT del split temporal solo hay clase-0 sin ningún pago → **separación perfecta trivial**.

Decisión — Opciones A y B implementadas

Opción	Features	AUC real	Uso en producción
A ☒ — Producción	60 features (incluye débito del tanque)	0.96	Cartera activa con historial de pagos
B ☒ — Disponible	19 features (gestiones + moras únicamente)	0.88	Clientes nuevos o sin historial de débito

Opción A — justificación: el historial de débito (pago_debito_3m) **está disponible en producción** para obligaciones en mora temprana. No es leakage. AUC = 0.96 es el valor real y reproducible.

Opción B — valor: AUC = 0.88 demuestra que el **comportamiento de cobranza per se** (gestiones, RPC, mora) tiene poder predictivo independiente del historial de pagos. Útil para ampliar cobertura.

Ambas opciones entrenadas y rastreadas en MLflow (feature_set = A / B). 4 combinaciones disponibles: A/B × random/temporal.

6. Dashboard

18 cards · Metabase · `localhost:3000/dashboard/4`

Tablero — visión analítica y operativa

Cards de negocio (1–7): comportamiento de la cartera

#	Card	Insight que expone
1	Evolución % Débito Exclusivo por Período	Tendencia de clase 1 en el tiempo
2	Volumen de Obligaciones por Período	Cohortes y concentración temporal
3	Segmentos A/B/C/D — Distribución Global	Qué fracción de la cartera es automatizable
4	Mix de Canales de Pago por Clase	Diferencias comportamentales entre clases
5	Efectividad de Gestiones por Clase	Qué gestiones predicen el pago
7	KPI Resumen — Último Período	Dashboard ejecutivo de un vistazo

Cards de modelos (8–10): comparación y explicabilidad

#	Card	Insight que expone
8	Comparativa AUC/KS por Modelo	Qué modelo rendir mejor en cada configuración
9	Estabilidad Train/Test/OOT	Ausencia de sobreajuste — confianza en producción
10	Top 20 Features SHAP	Qué variables explican el modelo

Cards de pipeline (11–18): trazabilidad y monitoreo del proceso

7. Operacionalización

DAG Airflow — ejecución programada y controlada

DAG `debit_ml_pipeline` — arquitectura de ejecución

```
gate_setup      → setup_artifacts_dir
gate_load_data   → load_data           (CSV → PostgreSQL · dedup · S11)
gate_build_model → build_analytical_model (JOIN 6 fuentes · 45,731 obs)
gate_build_features → build_features    (~240 features → parquets)
gate_select_features → select_features  (60 / 19 features · feature_cols.json)
gate_train       → train_model         (XGBoost + GBM + LogReg + MLflow)
gate_metabase    → provision_metabase  (18 cards · idempotente)
```

Cada gate: `ShortCircuitOperator` configurable desde `.env` o al disparar el DAG

Cada tarea: `DockerOperator` sobre `debit-network` → **reproducible en cualquier entorno**

Calendarizable: `@monthly` por defecto · parámetros `split_strategy` × `feature_set` por run

```
make airflow-trigger # pipeline completo
# Ejecución parcial desde UI: Trigger DAG → checkboxes por tarea
```

8. Conclusiones

Requerimientos cumplidos · accionables · próximos pasos

Requerimientos de la prueba — estado de cumplimiento

Requerimiento	Solución implementada	Resultado
R1 Modelo de datos analítico	6 tablas ORM SQLAlchemy · clave <code>(num_doc, obl17, f_analisis)</code> · 5 migraciones Alembic · 9 vistas SQL	✓
R2 Pipeline escalable	Airflow DAG <code>@monthly</code> · 7 tareas <code>DockerOperator</code> · gates configurables · <code>make pipeline</code>	✓
R3 Split Train/Test/OOT	8/5/4 períodos · justificación temporal documentada · diagnóstico AUC=1.0 identificado y resuelto	✓
R4 Desempeño del modelo	AUC = 0.96 · KS = 0.74 · Precision/Recall/F1 · Brier · Log Loss · Calibración · SHAP	✓
R5 Tablero análisis descriptivo	Metabase dashboard id=4 · 18 cards · EDA + modelos + pipeline · accionables de negocio	✓

Accionables inmediatos para el negocio

Prioridad	Accionable	Impacto
 Alta	Activar Segmento A en producción — desactivar gestión humana en obligaciones clase 1 con mora ≤ 10 días	Reducción de costos de gestión en ~79 % del volumen
 Alta	Umbral operativo ajustado — mover punto de corte según costo de falso negativo vs. costo de gestión	Maximizar ahorro neto
 Media	Despliegue Opción B para clientes sin historial de débito — AUC 0.88 amplía cobertura del modelo	Mayor cobertura sin degradar calidad
 Media	Monitoreo Segmento B — alerta automática cuando mora > 10 días en obligaciones clase 1 predicha	Prevención de deterioro
 Normal	Re-entrenamiento mensual via Airflow con monitoreo PSI sobre <code>prop_debito_3m</code> y score	Estabilidad del modelo en producción
 Normal	Trigger automático si AUC OOT < 0.90 en el próximo run mensual	Gobernanza del modelo

Conclusiones técnicas clave

Conclusión	Evidencia
El modelo es válido y robusto	AUC = 0.96, KS = 0.73, Train ≈ Test ≈ OOT sin sobreajuste
H1 es el hallazgo más importante	Clase-0 = sin pago — redefine el objetivo del modelo y explica el AUC inflado
La selección supervisada confirma el EDA	ANOVA elimina pago_fisico y pago_otros automáticamente → ambas fuentes convergen
El diagnóstico AUC=1.0 es transparente	Causa estructural identificada, documentada y resuelta — no es un error, es un insight
La solución es end-to-end y productizable	CSV → PostgreSQL → MLflow → Metabase · Airflow → re-entrenamiento mensual automatizado
Opción B agrega valor	AUC = 0.88 sin historial de débito — el comportamiento de cobranza per se predice el pago

Próximos pasos

1. **Umbral operativo:** ajustar punto de corte (actualmente KS-óptimo) mediante análisis costo-beneficio de gestión vs. falso negativo con el equipo de cobranza
2. **Monitoreo de drift:** PSI mensual sobre `prop_debito_3m` (top feature SHAP) y score del modelo — Airflow DAG ya calendarizado
3. **Despliegue dual A/B:** orquestar scoring con Opción A para cartera activa y Opción B para clientes sin historial, maximizando cobertura
4. **Re-entrenamiento automático:** trigger en DAG si $AUC_{OOT} < 0.90$ en run mensual — gobernanza del modelo sin intervención manual
5. **Convergencia LogReg:** aumentar `max_iter` en `LogisticRegressionDebitClassifier` para resolver `ConvergenceWarning` (ALERTA 3)

¡Gracias!

Jhon Fredy Correa Gomez

Dashboard → <http://localhost:3000/dashboard/4>

MLflow → <http://localhost:5000> · Airflow → <http://localhost:8080>

jonfredi12@gmail.com